

软件需求规格说明 V1.0

|    |    |      |    |    |             |       |
|----|----|------|----|----|-------------|-------|
|    |    |      |    |    | XT-XXX-SRS  |       |
|    |    |      |    |    |             |       |
| 标记 | 数量 | 修改单号 | 签字 | 日期 |             |       |
| 编制 |    |      | 会签 |    |             |       |
|    |    |      |    |    | XX 软件需求规格说明 |       |
|    |    |      |    |    |             |       |
| 校对 |    |      | 标检 |    | 共 51 页      | 第 1 页 |
| 审核 |    |      | 批准 |    |             |       |
| 会签 |    |      |    |    |             |       |

## 修订记录

| 版本号 | 修订状态 | 简要说明修订内容和范围 | 修订日期 | 修订人 | 批准日期 |
|-----|------|-------------|------|-----|------|
|     |      |             |      |     |      |
|     |      |             |      |     |      |
|     |      |             |      |     |      |
|     |      |             |      |     |      |

注：修订记录在体系文件发布后换版时使用，修订状态栏填写：A—增加，M—修改，D—删除

## 目 次

|                       |    |
|-----------------------|----|
| 1 范围 .....            | 2  |
| 1.1 标识 .....          | 2  |
| 1.2 系统概述 .....        | 2  |
| 1.3 文档概述 .....        | 2  |
| 2 需求 .....            | 2  |
| 2.1 要求的状态和方式 .....    | 2  |
| 2.2 功能需求 .....        | 4  |
| 2.2.1 数据处理模块 .....    | 4  |
| 2.2.2 模型训练模块 .....    | 11 |
| 2.2.3 模型管理模块 .....    | 18 |
| 2.2.4 大模型应用模块 .....   | 26 |
| 2.2.5 系统管理模块 .....    | 28 |
| 2.3 外部接口需求 .....      | 34 |
| 2.3.1 接口标识和接口图 .....  | 34 |
| 2.3.2 外部接口标识 .....    | 35 |
| 2.4 内部接口需求 .....      | 38 |
| 2.4.1 接口标识和接口图 .....  | 38 |
| 2.4.2 内部接口标识 .....    | 40 |
| 2.5 CSCI 内部数据需求 ..... | 42 |
| 2.6 界面要求 .....        | 43 |
| 2.7 适应性需求 .....       | 45 |
| 2.8 安全性需求 .....       | 46 |
| 2.9 CSCI 环境需求 .....   | 46 |
| 2.10 软件质量因素 .....     | 46 |
| 2.11 设计和实现约束 .....    | 47 |
| 3 需求可追踪性 .....        | 47 |
| 4 注释 .....            | 48 |

## 1 范围

### 1.1 标识

简要说明软件的标识号、名称、缩略名、版本号。

- a) 标识号：LLMT-SRS-001；
- b) 标题：离线大数据训练与应用系统；
- c) 缩略名：LLMT-System；
- d) 版本号：V1.0；
- e) 适用系统：大模型训练与应用系统。

### 1.2 系统概述

本系统（离线大数据训练与应用系统）旨在为个人 AI 应用提供从数据准备、模型训练到部署迭代的全生命周期支撑平台。

本软件的用途是：提供一体化的离线大模型训练与应用能力，包括多模态数据治理、分布式并行训练、模型版本管理与安全防护、软件工程文档自动生成及系统运维管理等功能，降低大模型训练门槛，提升资源利用效率，保障模型交付质量。

本软件的功能包括多模态数据处理、分布式模型训练、模型版本管理与安全、大模型应用生成、系统管理等五大功能。

本软件采用分层解耦架构，集成 PyTorch、DeepSpeed、Megatron-LM 等主流框架，支持混合并行训练与弹性资源调度。

- a) 需方：有 AI 需求的人员
- b) 用户：算法工程师、数据科学家、AI 应用开发人员、系统运维人员
- c) 开发方：学生小组

其他有关文档：

《开发手册》  
《系统设计文档》  
《详细设计文档》  
《测试与用户手册文档》

### 1.3 文档概述

本文档为《离线大数据训练与应用系统需求规格说明书》，旨在全面、准确地描述系统的各项软件需求，明确系统开发的目标与范围，作为项目团队进行概要设计、详细设计、系统实现及验收测试的依据。

本文档的主要内容包括：

**功能需求：**详细阐述数据处理、模型训练、模型管理、大模型应用及系统管理五大核心模块的业务功能；

**接口需求：**定义系统内部模块间接口、与外部系统的交互接口及 API 规范；

**数据需求：**说明数据模型、数据治理标准、血缘追踪机制及数据存储要求；

**界面需求：**提供统一 Web 界面，支持全流程可视化操作与监控；

**适应性需求：**描述系统对不同硬件环境（GPU 型号、系统）、不同模型规模的适配能力；

**合格性需求：**规定系统需满足的功能验收标准、性能基准及安全合规要求。

本文档适用于项目管理人员、系统架构师、软件设计师、开发工程师、测试工程师及运维人员等相关角色，是软件概要设计人员的设计输入，也是后续各阶段工作的基础依据。

## 2 需求

### 2.1 要求的状态和方式

本系统（离线大数据训练与应用系统）主要用于为 AI 应用提供从数据准备、模型训练到部

署迭代的全生命周期支撑。

本系统采用五层分层解耦架构，从上到下依次为：应用层、业务层、服务层、数据层、基础设施层。




图 1 架构图

各层间交互与数据流说明：

应用层与业务层交互：

- Web 管理界面通过 REST API 调用业务层接口，采用 HTTP 协议，JSON 数据格式
- 监控大屏通过 WebSocket 与业务层建立长连接，实时接收训练指标和告警推送
- API 接口采用 API Key + OAuth2.0 双重认证机制

业务层与服务层交互：

- 业务层各模块通过 gRPC 协议调用服务层服务，实现内部通信
- 模型训练模块调用训练服务提交训练任务，训练服务返回任务 ID 和状态
- 模型管理模块调用推理服务进行模型部署和在线推理

**服务层与数据层交互：**

- a) 训练服务通过 PostgreSQL 存储任务配置和状态
- b) 训练服务通过 InfluxDB 写入训练指标时序数据
- c) 推理服务通过 MinIO 读取模型文件
- d) 调度服务通过 Elasticsearch 记录调度日志

**数据层与基础设施层交互：**

- a) 各数据库组件以容器化方式运行在 Kubernetes 集群上
- b) MinIO 对象存储直接利用 GPU 的本地存储
- c) 基础设施层为上层提供统一的资源抽象和管理能力

表 1 软件功能项表

| 软件名称         | 功能项名称      | 功能标示符（Tag）                           | 状态和方式 |
|--------------|------------|--------------------------------------|-------|
| 离线大数据训练与应用系统 | 多模态数据加载    | OFFLINE_AI_DATA_LoadData             | 就绪    |
|              | 数据质量校验     | OFFLINE_AI_DATA_ValidateData         | 就绪    |
|              | 数据血缘追踪     | OFFLINE_AI_DATA_LineageTrack         | 活动    |
|              | 混合并行配置     | OFFLINE_AI_TRAIN_ConfigureParallel   | 就绪    |
|              | 分布式训练启动    | OFFLINE_AI_TRAIN_StartTraining       | 就绪    |
|              | 训练任务监控     | OFFLINE_AI_TRAIN_MonitorTraining     | 活动    |
|              | 训练任务暂停     | OFFLINE_AI_TRAIN_PauseTraining       | 活动    |
|              | 训练任务恢复     | OFFLINE_AI_TRAIN_ResumeTraining      | 活动    |
|              | 训练任务动态扩缩容  | OFFLINE_AI_TRAIN_ScaleTraining       | 训练    |
|              | 模型版本管理     | OFFLINE_AI_MODEL_VersionControl      | 就绪    |
|              | 模型版本回滚     | OFFLINE_AI_MODEL_Rollback            | 活动    |
|              | 容器镜像漏洞扫描   | OFFLINE_AI_MODEL_ClaireScan          | 就绪    |
|              | API 调用频率限制 | OFFLINE_AI_MODEL_RateLimit           | 活动    |
|              | 差分隐私保护     | OFFLINE_AI_MODEL_DifferentialPrivacy | 活动    |
|              | 联邦学习       | OFFLINE_AI_MODEL_FederatedLearning   | 训练    |
|              | 文档自动生成     | OFFLINE_AI_APP_DocGenerate           | 就绪    |
|              | 日志管理       | OFFLINE_AI_SYS_LogManage             | 空闲    |
|              | 用户管理       | OFFLINE_AI_SYS_UserManage            | 就绪    |
|              | 角色权限管理     | OFFLINE_AI_SYS_RoleManage            | 就绪    |
|              | 监控大屏展示     | OFFLINE_AI_SYS_MonitorDashboard      | 活动    |

**2.2 功能需求****2.2.1 数据处理模块****a) 数据处理模块用例图：**

下图为数据处理模块的用例图，明确了模块的操作用户（数据工程师、AI 算法工程师）、核心用例（多模态数据加载、数据质量校验、数据血缘追踪）及用例的包含/扩展关系，定义了模块的功能范围与交互逻辑。




图 2 数据处理模块用例图

b) 需求用例描述：

表 2 多模态数据加载

|      |                                                                    |      |            |
|------|--------------------------------------------------------------------|------|------------|
| 用例编号 | OFFLINE_AI_DATA_LoadData                                           | 用例名称 | 多模态数据加载    |
| 编写者  | 学生小组                                                               | 时间   | 2026-03-23 |
| 触发事件 | 数据工程师上传或采集多模态数据文件                                                  |      |            |
| 用例描述 | 系统支持文本、图像、音频等异构数据的统一加载，通过自定义 Dataset 类实现多模态数据的自动识别和预处理，支持批量上传和断点续传 |      |            |
| 参与者  | 数据工程师、系统                                                           |      |            |
| 前提条件 | 1. 用户已登录系统<br>2. 用户具有数据处理权限<br>3. 存储空间充足                           |      |            |
| 后续条件 | 1. 数据文件已上传到对象存储                                                    |      |            |

|       |                                                                                                                                                                                                                                                                                                                 |
|-------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|       | <ol style="list-style-type: none"> <li>2. 数据元信息已记录到数据库</li> <li>3. 数据已通过初步验证</li> </ol>                                                                                                                                                                                                                         |
| 主事件流  | <ol style="list-style-type: none"> <li>1. 用户进入数据加载界面</li> <li>2. 选择要上传的数据文件（支持多选）</li> <li>3. 系统自动识别数据类型（文本/图像/音频）</li> <li>4. 显示数据预览信息（文件大小、格式、采样率等）</li> <li>5. 用户确认上传参数（存储路径、命名规则）</li> <li>6. 系统执行文件上传，显示上传进度</li> <li>7. 上传完成后，系统自动提取数据元信息</li> <li>8. 记录数据血缘信息（来源、时间、操作人）</li> <li>9. 返回上传成功提示</li> </ol> |
| 其他事件流 | <ol style="list-style-type: none"> <li>1. 如文件格式不支持，系统提示错误并列出支持的格式列表</li> <li>2. 如存储空间不足，系统提示并建议清理空间</li> <li>3. 如上传中断（网络原因），系统支持断点续传</li> <li>4. 如文件已存在，系统提示覆盖或跳过</li> <li>5. 如数据损坏，系统校验失败并提示用户</li> </ol>                                                                                                      |
| 异常处理  | <ol style="list-style-type: none"> <li>1. 文件格式异常：返回详细错误信息和格式要求</li> <li>2. 存储空间不足：提示清理空间或扩容</li> <li>3. 网络异常：自动重试 3 次，失败后提示手动重试</li> <li>4. 权限异常：提示用户联系管理员</li> </ol>                                                                                                                                           |
| 业务规则  | <ol style="list-style-type: none"> <li>1. 单个文件大小限制：≤10GB</li> <li>2. 批量上传文件数量：≤10 个</li> <li>3. 支持的数据格式：TXT、CSV、JSON、PDF、JPG、PNG、MP3、WAV 等 15 种以上</li> <li>4. 文件命名规则：禁止特殊字符，支持中文</li> </ol>                                                                                                                     |






表 3 数据质量校验

|      |                                                                          |      |            |
|------|--------------------------------------------------------------------------|------|------------|
| 用例编号 | OFFLINE_AI_DATA_ValidateData                                             | 用例名称 | 数据质量校验     |
| 编写者  | 学生小组                                                                     | 时间   | 2026-03-23 |
| 触发事件 | 数据加载完成或用户手动触发校验                                                          |      |            |
| 用例描述 | 集成 Great Expectations 框架，对训练数据进行自动质量校验，包括完整性、一致性、时效性、准确性四个维度，生成质量报告和修复建议 |      |            |
| 参与者  | 数据工程师、系统                                                                 |      |            |
| 前提条件 | 1. 数据已上传到对象存储<br>2. 数据元信息已记录<br>3. Great Expectations 配置就绪               |      |            |
| 后续条件 | 1. 质量报告已生成<br>2. 校验结果已记录到数据库                                             |      |            |

|       |                                                                                                                                                                                                                                                                                                                       |
|-------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|       | 3. 不合格数据已标记                                                                                                                                                                                                                                                                                                           |
| 主事件流  | <ol style="list-style-type: none"> <li>1. 用户选择要校验的数据集</li> <li>2. 系统执行完整性检查（缺失值、空值、重复值）</li> <li>3. 系统执行一致性检查（格式、类型、取值范围）</li> <li>4. 系统执行时效性检查（采集时间、更新时间）</li> <li>5. 系统执行准确性检查（规则引擎、统计方法）</li> <li>6. 系统计算数据质量评分（0-100 分）</li> <li>7. 生成质量报告，包含问题清单和修复建议</li> <li>8. 校验结果写入数据库</li> <li>9. 用户查看报告并决定是否修复</li> </ol> |
| 其他事件流 | <ol style="list-style-type: none"> <li>1. 如数据质量评分低于 60 分，系统自动告警</li> <li>2. 如发现严重质量问题，系统阻止数据进入训练</li> <li>3. 如用户选择自动修复，系统执行修复脚本</li> <li>4. 如用户选择跳过，系统记录原因</li> </ol>                                                                                                                                                 |
| 异常处理  | <ol style="list-style-type: none"> <li>1. 校验规则配置错误：返回详细错误信息</li> <li>2. 数据访问失败：提示检查存储权限</li> <li>3. 校验超时：记录超时，建议分批校验</li> </ol>                                                                                                                                                                                       |
| 业务规则  | <ol style="list-style-type: none"> <li>1. 完整性：缺失率<math>\leq 5\%</math>为合格</li> <li>2. 一致性：格式一致率<math>\geq 98\%</math>为合格</li> <li>3. 时效性：数据更新时间<math>\leq 7</math> 天为合格</li> <li>4. 准确性：异常值比例<math>\leq 1\%</math>为合格</li> <li>5. 综合评分<math>\geq 80</math> 分为合格</li> </ol>                                            |




表 4 数据血缘追踪

|      |                                                     |      |            |
|------|-----------------------------------------------------|------|------------|
| 用例编号 | OFFLINE_AI_DATA_LineageTrack                        | 用例名称 | 数据血缘追踪     |
| 编写者  | 学生小组                                                | 时间   | 2026-03-23 |
| 触发事件 | 数据加载、转换、使用的全生命周期                                    |      |            |
| 用例描述 | 建立数据血缘追踪机制，记录数据的来源、转换过程、使用情况，生成数据依赖关系图谱，支持问题溯源和影响分析 |      |            |

|       |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |
|-------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 参与者   | 数据工程师、AI 算法工程师、系统                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       |
| 前提条件  | 1. 数据已加载到系统<br>2. 数据已使用（训练或推理）                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |
| 后续条件  | 1. 血缘关系已记录<br>2. 依赖关系图谱已生成<br>3. 支持追溯查询                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                 |
| 主事件流  | 1. 数据加载时：记录数据来源（上传者、时间、原始位置）<br>2. 数据转换时：记录转换规则、转换时间、转换前后的数据版本<br>3. 数据使用时：记录使用场景（训练任务 ID）、使用时间、使用结果<br>4. 系统自动分析数据依赖关系<br>5. 生成数据血缘图谱<br>6. 支持用户查询某个数据的完整血缘链路<br>7. 支持影响分析：某个数据变更会影响哪些下游任务                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |
| 其他事件流 | 1. 如发现数据质量问题，可快速定位问题源头<br>2. 如需要回滚数据，可查看历史版本<br>3. 如数据被多个任务使用，系统提示风险                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    |
| 异常处理  | 1. 血缘记录失败：不影响主流程，后台重试<br>2. 图谱生成失败：提示用户手动检查                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |
| 业务规则  | 1. 支持至少 3 层血缘关系追溯<br>2. 血缘记录永久保存，不可删除<br>3. 数据血缘关系变更需记录变更日志                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |
| 功能图   | <pre> graph TD     Start(( )) --&gt; Load[数据加载时，记录来源（上传者/时间/原始位置）]     Load --&gt; Transform[数据转换时，记录规则/版本变化]     Transform --&gt; Use[数据使用时，记录场景/时间/结果]     Use --&gt; Analyze[系统分析数据依赖关系]     Analyze --&gt; Generate[生成数据血缘图谱（支持≥3层追溯）]     Generate --&gt; Success{图谱生成成功？}     Success -- 否 --&gt; Manual[提示用户手动检查]     Success -- 是 --&gt; Support[支持血缘链路查询 + 数据变更影响分析]     Support --&gt; Quality{发现数据质量问题？}     Support --&gt; Rollback{需要回滚数据？}     Support --&gt; Risk{数据被多个任务使用？}     Quality -- 是 --&gt; Locate[快速定位问题源头]     Rollback -- 是 --&gt; History[查看历史版本，支持回滚]     Risk -- 是 --&gt; Alert[系统提示使用风险]     Manual --&gt; End(( ))     Locate --&gt; End     History --&gt; End     Alert --&gt; End     Support --&gt; Save[血缘记录永久保存，变更留痕]     Save --&gt; End </pre> |

2.2.2 模型训练模块

a) 模型训练模块用例图：

下图为模型训练模块的用例图，明确了模块的操作用户（AI 算法工程师、项目管理者）、核心用例（训练任务恢复、训练动态扩容、混合并行配置、分布式训练启动、训练任务暂停、训练任务监控）及用例的包含/扩展关系，定义了模块的功能范围与交互逻辑。




图 3 模型训练模块用例图

b) 需求用例描述：

表 5 混合并行配置

|      |                                                              |      |            |
|------|--------------------------------------------------------------|------|------------|
| 用例编号 | OFFLINE_AI_TRAIN_ConfigureParallel                           | 用例名称 | 混合并行配置     |
| 编写者  | 学生小组                                                         | 时间   | 2026-03-23 |
| 触发事件 | 数据工程师上传或采集多模态数据文件                                            |      |            |
| 用例描述 | 支持一键式混合并行配置，用户选择并行策略（数据并行、模型并行、流水线并行），系统自动检测硬件配置并生成最优的并行配置文件 |      |            |
| 参与者  | AI 算法工程师、系统                                                  |      |            |
| 前提条件 | 1. 用户已登录系统<br>2. 用户具有训练配置权限                                  |      |            |

|       |                                                                                                                                                                                                                     |
|-------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|       | 3. 训练任务已创建                                                                                                                                                                                                          |
| 后续条件  | 1. 并行配置文件已生成<br>2. 配置已保存到数据库<br>3. 可提交训练任务                                                                                                                                                                          |
| 主事件流  | 1. 用户进入训练配置界面<br>2. 选择训练框架（PyTorch/DeepSpeed/Megatron-LM）<br>3. 选择并行策略（数据并行/模型并行/流水线并行）<br>4. 系统自动检测 GPU 硬件配置（GPU 数量、显存、带宽）<br>5. 系统推荐最优并行策略（基于模型规模和硬件）<br>6. 用户确认或调整配置参数<br>7. 系统生成配置文件（YAML 格式）<br>8. 保存配置并预览配置内容 |
| 其他事件流 | 1. 如硬件资源不足，系统提示并建议降级或扩容<br>2. 如配置参数冲突，系统高亮显示冲突项<br>3. 如用户选择自动优化，系统自动调整参数                                                                                                                                            |
| 异常处理  | 1. 硬件检测失败：返回错误信息，建议检查集群状态<br>2. 配置生成失败：提示参数错误并提供修正建议<br>3. 保存失败：提示数据库异常                                                                                                                                             |
| 业务规则  | 1. 支持单策略或混合策略<br>2. 模型并行要求：单卡显存 $\geq$ 模型大小/并行星数<br>3. 流水线并行要求：并行星数 $\leq$ GPU 数量<br>4. 批大小 $\geq$ 微批次大小 $\times$ 梯度累积步数                                                                                            |

表 6 分布式训练启动

|      |                                                                                                                                                 |      |            |
|------|-------------------------------------------------------------------------------------------------------------------------------------------------|------|------------|
| 用例编号 | OFFLINE_AI_TRAIN_StartTraining                                                                                                                  | 用例名称 | 分布式训练启动    |
| 编写者  | 学生小组                                                                                                                                            | 时间   | 2026-03-23 |
| 触发事件 | AI 算法工程师提交训练任务                                                                                                                                  |      |            |
| 用例描述 | 用户提交训练任务后，系统自动分配 GPU 资源，加载训练配置和数据，初始化训练环境，启动分布式训练进程                                                                                             |      |            |
| 参与者  | AI 算法工程师、系统                                                                                                                                     |      |            |
| 前提条件 | 1. 训练配置已完成<br>2. 训练数据已准备并校验通过<br>3. GPU 资源充足                                                                                                    |      |            |
| 后续条件 | 1. 训练任务已启动<br>2. 训练进程正常运行<br>3. 监控指标正常采集                                                                                                        |      |            |
| 主事件流 | 1. 用户提交训练任务<br>2. 系统验证训练配置和数据路径<br>3. 系统分配 GPU 资源（根据配置需要的 GPU 数量）<br>4. 系统加载训练配置文件到 GPU 节点<br>5. 系统从对象存储加载训练数据<br>6. 系统初始化分布式训练环境（设置 NCCL 通信后端） |      |            |

|       |                                                                                                                 |
|-------|-----------------------------------------------------------------------------------------------------------------|
|       | <div>7. 系统启动训练进程（主进程和 Worker 进程）</div> <div>8. 训练开始，系统开始采集监控指标</div> <div>9. 返回任务启动成功，显示任务 ID</div>             |
| 其他事件流 | <div>1. 如 GPU 资源不足，任务进入等待队列</div> <div>2. 如配置验证失败，返回详细错误信息</div> <div>3. 如数据加载失败，检查数据路径和权限</div>                |
| 异常处理  | <div>1. GPU 分配失败：提示资源不足，建议调整并行策略或等待</div> <div>2. 环境初始化失败：返回错误日志，建议检查网络和依赖</div> <div>3. 训练启动失败：自动回滚，释放资源</div> |
| 业务规则  | <div>1. 任务等待超时时间：2 小时</div> <div>2. 训练超时时间：默认 7 天，可配置</div>                                                     |
| 功能图   | <div></div>                                                                                                     |

表 7 训练任务监控

|      |                                                                       |      |            |
|------|-----------------------------------------------------------------------|------|------------|
| 用例编号 | OFFLINE_AI_TRAIN_MonitorTraining                                      | 用例名称 | 训练任务监控     |
| 编写者  | 学生小组                                                                  | 时间   | 2026-03-23 |
| 触发事件 | 训练任务运行过程中                                                             |      |            |
| 用例描述 | 提供 TensorBoard 集成界面，实时展示训练损失曲线、准确率、学习率等指标，同时监控 GPU 利用率、显存占用、通信延迟等资源指标 |      |            |

|       |                                                                                                                                                                                                                                                                                             |
|-------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 参与者   | AI 算法工程师、项目管理者、系统                                                                                                                                                                                                                                                                           |
| 前提条件  | <ol style="list-style-type: none"> <li>1. 训练任务正在运行</li> <li>2. TensorBoard 服务已启动</li> </ol>                                                                                                                                                                                                 |
| 后续条件  | <ol style="list-style-type: none"> <li>1. 监控数据实时更新</li> <li>2. 异常情况及时告警</li> </ol>                                                                                                                                                                                                          |
| 主事件流  | <ol style="list-style-type: none"> <li>1. 用户打开训练监控界面</li> <li>2. 系统实时显示训练进度（当前 Epoch、Step）</li> <li>3. 系统实时展示训练指标（损失曲线、准确率曲线、学习率变化）</li> <li>4. 系统实时展示资源指标（GPU 利用率、显存占用、通信延迟）</li> <li>5. 系统自动检测训练异常（梯度爆炸、NaN 损失）</li> <li>6. 如发现异常，系统自动告警（界面提示+邮件/短信）</li> <li>7. 用户可查看历史训练记录对比</li> </ol> |
| 其他事件流 | <ol style="list-style-type: none"> <li>1. 如监控数据刷新延迟，检查网络连接</li> <li>2. 如 GPU 利用率异常低，检查训练配置</li> <li>3. 如通信延迟过高，提示检查网络拓扑</li> </ol>                                                                                                                                                          |
| 异常处理  | <ol style="list-style-type: none"> <li>1. 监控服务异常：自动重启服务，记录错误日志</li> <li>2. 数据采集失败：不影响训练，后台重试</li> <li>3. 告警发送失败：记录日志，界面提示</li> </ol>                                                                                                                                                        |
| 业务规则  | <ol style="list-style-type: none"> <li>1. 监控数据刷新频率：每 5 秒更新一次</li> <li>2. 异常检测阈值：梯度<math>&gt;1e6</math>、损失=NaN</li> <li>3. 告警级别：紧急（立即停止）、警告（提示）、通知（记录）</li> </ol>                                                                                                                            |






表 8 训练任务暂停

|      |                                                                         |      |            |
|------|-------------------------------------------------------------------------|------|------------|
| 用例编号 | OFFLINE_AI_TRAIN_PauseTraining                                          | 用例名称 | 训练任务暂停     |
| 编写者  | 学生小组                                                                    | 时间   | 2026-03-23 |
| 触发事件 | AI 算法工程师主动暂停训练任务                                                        |      |            |
| 用例描述 | 用户可以暂停正在运行的训练任务，系统自动保存当前训练状态（Checkpoint），释放 GPU 资源，任务状态更新为“已暂停”         |      |            |
| 参与者  | AI 算法工程师、系统                                                             |      |            |
| 前提条件 | 1. 训练任务正在运行<br>2. 用户具有该任务的控制权限                                          |      |            |
| 后续条件 | 1. 训练进程已停止<br>2. Checkpoint 已保存到对象存储<br>3. GPU 资源已释放<br>4. 任务状态更新为“已暂停” |      |            |
| 主事件流 | 1. 用户点击“暂停训练”按钮<br>2. 系统提示确认暂停（避免误操作）<br>3. 用户确认暂停                      |      |            |

|       |                                                                                                                                                      |
|-------|------------------------------------------------------------------------------------------------------------------------------------------------------|
|       | 4. 系统等待当前训练 Step 完成<br>5. 系统保存训练 Checkpoint（模型参数、优化器状态、随机数种子）<br>6. 系统停止训练进程<br>7. 系统释放 GPU 资源<br>8. 更新任务状态为“已暂停”<br>9. 返回暂停成功，显示 Checkpoint 路径和保存时间 |
| 其他事件流 | 1. 如训练 Step 执行时间过长，用户可选择强制暂停<br>2. 如 Checkpoint 保存失败，系统提示并重试 3 次<br>3. 如资源释放失败，系统记录错误日志                                                              |
| 异常处理  | 1. 训练进程停止失败：强制终止进程<br>2. Checkpoint 保存失败：提示用户，任务状态标记为“异常”<br>3. 资源释放失败：记录错误，后台继续尝试释放                                                                 |
| 业务规则  | 1. 暂停操作有 5 秒确认时间，避免误操作<br>2. Checkpoint 保存时间： $\leq 2$ 分钟<br>3. 暂停后的任务保留 7 天，7 天后自动清理                                                                |


表 9 训练任务恢复

|       |                                                                                                                                                                                                                                                 |      |            |
|-------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|------------|
| 用例编号  | OFFLINE_AI_TRAIN_ResumeTraining                                                                                                                                                                                                                 | 用例名称 | 训练任务恢复     |
| 编写者   | 学生小组                                                                                                                                                                                                                                            | 时间   | 2026-03-23 |
| 触发事件  | AI 算法工程师恢复已暂停的训练任务                                                                                                                                                                                                                              |      |            |
| 用例描述  | 用户可以恢复已暂停的训练任务，系统自动加载 Checkpoint，恢复训练状态，重新分配 GPU 资源，继续训练                                                                                                                                                                                        |      |            |
| 参与者   | AI 算法工程师、系统                                                                                                                                                                                                                                     |      |            |
| 前提条件  | 1. 训练任务状态为“已暂停”<br>2. Checkpoint 文件存在且完整<br>3. GPU 资源充足                                                                                                                                                                                         |      |            |
| 后续条件  | 1. 训练任务已恢复<br>2. 训练状态已从 Checkpoint 加载<br>3. 训练继续进行<br>4. 任务状态更新为“运行中”                                                                                                                                                                           |      |            |
| 主事件流  | 1. 用户选择要恢复的训练任务<br>2. 系统显示 Checkpoint 信息（保存时间、训练 Step）<br>3. 用户确认恢复<br>4. 系统验证 Checkpoint 文件完整性<br>5. 系统分配 GPU 资源（与原配置相同）<br>6. 系统加载 Checkpoint（模型参数、优化器状态、随机数种子）<br>7. 系统初始化训练环境<br>8. 系统启动训练进程<br>9. 训练从暂停处继续，开始采集监控指标<br>10. 返回恢复成功，显示当前训练进度 |      |            |
| 其他事件流 | 1. 如 GPU 资源不足，任务进入等待队列<br>2. 如 Checkpoint 损坏，提示用户选择其他 Checkpoint 或重新训练                                                                                                                                                                          |      |            |

|      |                                                                                         |
|------|-----------------------------------------------------------------------------------------|
|      | 3. 如用户选择修改配置（如学习率），系统支持在恢复时调整超参数                                                        |
| 异常处理 | 1. Checkpoint 加载失败：返回详细错误，提示检查文件完整性<br>2. 环境初始化失败：检查依赖和网络，重试 3 次<br>3. 训练启动失败：自动回滚，释放资源 |
| 业务规则 | 1. 支持从任意 Checkpoint 恢复<br>2. 恢复时可修改部分超参数（如学习率）<br>3. Checkpoint 保留时间：30 天               |

表 10 训练任务动态扩缩容

|       |                                                                                                                                                                                                                                                                                            |         |            |
|-------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------|------------|
| 用例编号  | OFFLINE_AI_TRAIN_ScaleTraining                                                                                                                                                                                                                                                             | 用 例 名 称 | 训练任务动态扩缩容  |
| 编写者   | 学生小组                                                                                                                                                                                                                                                                                       | 时间      | 2026-03-23 |
| 触发事件  | 训练任务运行过程中                                                                                                                                                                                                                                                                                  |         |            |
| 用例描述  | 支持在训练过程中动态调整 GPU 资源，包括扩容（增加 GPU 节点）和缩容（减少 GPU 节点），系统自动平衡数据分布，确保训练一致性                                                                                                                                                                                                                       |         |            |
| 参与者   | AI 算法工程师、系统                                                                                                                                                                                                                                                                                |         |            |
| 前提条件  | 1. 训练任务正在运行<br>2. 有足够的空闲资源（扩容时）                                                                                                                                                                                                                                                            |         |            |
| 后续条件  | 1. GPU 资源已调整<br>2. 数据已重新分布<br>3. 训练继续进行<br>4. 准确率下降 $\leq 1\%$                                                                                                                                                                                                                             |         |            |
| 主事件流  | 1. 用户发起扩缩容请求<br>2. 系统验证资源可用性<br>3. 系统等待当前训练 Step 完成<br>4. 系统保存当前 Checkpoint<br>5. 系统执行扩缩容操作<br>扩容流程：<br>分配新的 GPU 节点<br>将模型和优化器状态复制到新节点<br>重新分布训练数据<br>缩容流程：<br>从要释放的节点迁移数据和状态<br>合并数据和状态到保留的节点<br>释放 GPU 资源<br>6. 系统重新初始化通信组<br>7. 系统加载 Checkpoint 并恢复训练<br>8. 训练继续，自动调整并行策略<br>9. 返回扩缩容成功 |         |            |
| 其他事件流 | 1. 如资源不足，系统提示并加入等待队列<br>2. 如扩缩容失败，系统自动回滚到原状态<br>3. 如系统检测到性能瓶颈，可自动发起扩容建议                                                                                                                                                                                                                    |         |            |



### 2.2.3 模型管理模块

#### a) 模型管理模块用例图：

下图为模型管理模块的用例图，明确了模块的操作用户（模型运维工程师、系统管理员、AI 算法工程师、数据提供方、外部应用）、核心用例（模型版本回滚、模型版本管理、容器镜像漏洞扫描、差分隐私保护、联邦学习、API 调用频率限制）及用例的包含/扩展关系，定义了模块的功能范围与交互逻辑。




图 4 模型管理模块用例图

b) 需求用例描述：

表 11 模型版本管理

|      |                                            |      |            |
|------|--------------------------------------------|------|------------|
| 用例编号 | OFFLINE_AI_MODEL_VersionControl            | 用例名称 | 模型版本管理     |
| 编写者  | 学生小组                                       | 时间   | 2026-03-23 |
| 触发事件 | 模型训练完成或模型上传                                |      |            |
| 用例描述 | 基于 Git-like 分支策略实现模型版本管理,自动生成版本号,记录训练元数据(超 |      |            |

|       |                                                                                                                                                                                                                                                                                                                  |
|-------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|       | 参数、数据集版本、训练时间）和性能指标（准确率、F1 分数、损失值）                                                                                                                                                                                                                                                                               |
| 参与者   | 模型运维工程师、AI 算法工程师、系统                                                                                                                                                                                                                                                                                              |
| 前提条件  | 1. 模型文件已生成<br>2. 训练日志已保存<br>3. 存储空间充足                                                                                                                                                                                                                                                                            |
| 后续条件  | 1. 模型版本已保存到中央仓库<br>2. 元数据已记录到数据库<br>3. 可查询和对比不同版本                                                                                                                                                                                                                                                                |
| 主事件流  | 1. 系统检测到模型训练完成或模型上传<br>2. 系统自动生成模型版本号（如 v1.0.0）<br>3. 系统记录训练元数据<br>训练时间、训练时长<br>数据集版本、数据来源<br>训练超参数（学习率、批大小、优化器、损失函数）<br>训练框架（PyTorch/DeepSpeed/Megatron-LM）<br>4. 系统记录模型性能指标<br>训练集准确率、验证集准确率<br>F1 分数、精确率、召回率<br>训练损失曲线<br>推理速度、延迟<br>5. 系统上传模型文件到对象存储（MinIO）<br>6. 系统在数据库中创建版本记录<br>7. 系统返回版本保存成功，显示版本号和元数据摘要 |
| 其他事件流 | 1. 如用户选择手动上传模型，可手动输入部分元数据<br>2. 如模型版本号冲突，系统自动递增版本号<br>3. 如用户添加版本标签（如 stable、latest、experimental），系统记录标签                                                                                                                                                                                                          |
| 异常处理  | 1. 元数据记录失败：记录错误日志，提示手动补充<br>2. 版本号生成冲突：系统自动处理，确保唯一性<br>3. 模型文件上传失败：检查网络和权限，自动重试 3 次                                                                                                                                                                                                                              |
| 业务规则  | 1. 版本号格式：主版本.次版本.修订号（如 v1.2.3）<br>2. 主版本：重大架构变更或不兼容更新<br>3. 次版本：新功能或性能优化<br>4. 修订号：Bug 修复或小改进<br>5. 支持版本标签                                                                                                                                                                                                       |

表 12 模型版本回滚

|      |                                                      |      |            |
|------|------------------------------------------------------|------|------------|
| 用例编号 | OFFLINE_AI_MODEL_Rollback                            | 用例名称 | 模型版本回滚     |
| 编写者  | 学生小组                                                 | 时间   | 2026-03-23 |
| 触发事件 | 当前模型出现问题或需要返回稳定版本                                    |      |            |
| 用例描述 | 支持一键回滚到任意历史版本，自动恢复模型文件和对应的元数据（超参数、数据集版本、性能指标），更新推理服务 |      |            |

|       |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |
|-------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 参与者   | 模型运维工程师、系统                                                                                                                                                                                                                                                                                                                                                                                                                                                                              |
| 前提条件  | <ol style="list-style-type: none"> <li>1. 存在至少一个历史模型版本</li> <li>2. 用户具有模型管理权限</li> <li>3. 历史模型文件完整</li> </ol>                                                                                                                                                                                                                                                                                                                                                                           |
| 后续条件  | <ol style="list-style-type: none"> <li>1. 推理服务已更新到历史版本</li> <li>2. 元数据已恢复</li> <li>3. 回滚日志已记录</li> <li>4. 当前版本标记已更新</li> </ol>                                                                                                                                                                                                                                                                                                                                                          |
| 主事件流  | <ol style="list-style-type: none"> <li>1. 用户进入模型版本管理界面</li> <li>2. 系统显示所有历史版本列表（版本号、标签、保存时间）</li> <li>3. 用户选择要回滚的目标版本</li> <li>4. 系统显示回滚预览（版本差异对比、影响范围）</li> <li>5. 用户确认回滚操作</li> <li>6. 系统保存当前版本的快照（便于再次回滚）</li> <li>7. 系统从对象存储加载历史模型文件</li> <li>8. 系统恢复该版本的元数据 <ul style="list-style-type: none"> <li>训练超参数</li> <li>数据集版本</li> <li>性能指标</li> </ul> </li> <li>9. 系统更新推理服务，加载历史模型</li> <li>10. 系统验证模型加载成功</li> <li>11. 系统记录回滚日志（操作人、回滚原因、回滚时间）</li> <li>12. 返回回滚成功，显示当前版本信息</li> </ol> |
| 其他事件流 | <ol style="list-style-type: none"> <li>1. 如需要快速回滚，提供“快速回滚”按钮（跳过预览）</li> <li>2. 如模型文件损坏，系统提示选择其他版本或重新训练</li> <li>3. 如推理服务更新失败，系统尝试回滚到回滚前的状态</li> </ol>                                                                                                                                                                                                                                                                                                                                   |
| 异常处理  | <ol style="list-style-type: none"> <li>1. 历史模型加载失败：提示文件损坏，建议重新训练</li> <li>2. 元数据恢复失败：记录警告，不影响模型加载</li> <li>3. 推理服务更新失败：自动回滚到原版本，提示管理员</li> </ol>                                                                                                                                                                                                                                                                                                                                        |
| 业务规则  | <ol style="list-style-type: none"> <li>1. 回滚操作需要二次确认</li> <li>2. 回滚后，原版本保留，可再次回滚</li> <li>3. 回滚操作需要记录详细日志（审计要求）</li> <li>4. 支持批量回滚（多个模型同时回滚）</li> </ol>                                                                                                                                                                                                                                                                                                                                 |




表 13 容器镜像漏洞扫描

|      |                                                                                                                                                                                                                               |      |            |
|------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|------------|
| 用例编号 | OFFLINE_AI_MODEL_ClairScan                                                                                                                                                                                                    | 用例名称 | 容器镜像漏洞扫描   |
| 编写者  | 学生小组                                                                                                                                                                                                                          | 时间   | 2026-03-23 |
| 触发事件 | 定时扫描或管理员手动触发                                                                                                                                                                                                                  |      |            |
| 用例描述 | 集成 Clair 工具，对容器镜像进行静态安全扫描，检测已知漏洞（CVE），生成漏洞报告，对高危漏洞自动告警                                                                                                                                                                        |      |            |
| 参与者  | 系统管理员、系统                                                                                                                                                                                                                      |      |            |
| 前提条件 | 1. Clair 工具已部署并配置<br>2. 镜像仓库已配置<br>3. 扫描策略已配置（频率、镜像范围）                                                                                                                                                                        |      |            |
| 后续条件 | 1. 漏洞扫描报告已生成<br>2. 漏洞数据已记录到数据库<br>3. 高危漏洞已告警                                                                                                                                                                                  |      |            |
| 主事件流 | 1. 系统根据扫描策略自动触发扫描（或管理员手动触发）<br>2. Clair 从镜像仓库拉取镜像层信息<br>3. Clair 分析镜像层，检测软件包和版本<br>4. Clair 查询漏洞数据库（NVD、Ubuntu CVE Tracker 等）<br>5. 生成漏洞清单<br>CVE 编号<br>漏洞等级（Critical/High/Medium/Low）<br>受影响的软件包和版本<br>漏洞描述<br>修复建议（升级版本或补丁） |      |            |



|       |                                                                                                                      |
|-------|----------------------------------------------------------------------------------------------------------------------|
|       | 6. 系统评估镜像安全风险评分<br>7. 生成扫描报告（HTML/PDF 格式）<br>8. 如发现高危漏洞（Critical/High），系统自动告警<br>9. 扫描报告保存到数据库<br>10. 管理员查看报告并决定是否修复 |
| 其他事件流 | 1. 如镜像已扫描过，系统显示历史扫描结果对比<br>2. 如管理员需要，可仅扫描特定的镜像层<br>3. 如漏洞数据库更新，系统可重新扫描历史镜像                                           |
| 异常处理  | 1. 镜像拉取失败：检查镜像仓库和网络，自动重试 3 次<br>2. Clair 服务异常：自动重启 Clair 服务<br>3. 漏洞数据库查询失败：使用本地缓存，后台同步                              |
| 业务规则  | 1. 扫描频率：每日自动扫描<br>2. 高危漏洞定义：Critical 级别<br>3. 重要漏洞定义：High 级别<br>4. 高危漏洞修复时限：24 小时<br>5. 重要漏洞修复时限：7 天                 |

表 14 API 调用频率限制

|      |                                                                                                                                                                                                                                                            |      |            |
|------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|------------|
| 用例编号 | OFFLINE_AI_MODEL_RateLimit                                                                                                                                                                                                                                 | 用例名称 | API 调用频率限制 |
| 编写者  | 学生小组                                                                                                                                                                                                                                                       | 时间   | 2026-03-23 |
| 触发事件 | 外部应用调用模型推理 API                                                                                                                                                                                                                                             |      |            |
| 用例描述 | 对模型推理 API 实施调用频率限制，防止恶意调用和资源耗尽，保障服务稳定性。支持按用户、IP、API Key 等多维度限流                                                                                                                                                                                             |      |            |
| 参与者  | 外部应用、系统                                                                                                                                                                                                                                                    |      |            |
| 前提条件 | 1. API 服务已部署<br>2. 限流策略已配置<br>3. Redis 缓存已启动                                                                                                                                                                                                               |      |            |
| 后续条件 | 1. 调用频率受控<br>2. 超限请求被拒绝<br>3. 限流日志已记录                                                                                                                                                                                                                      |      |            |
| 主事件流 | 1. 外部应用发起 API 请求<br>2. 系统提取请求标识（用户 ID、IP 等）<br>3. 系统检查该标识在时间窗口内的调用次数<br>4. 使用滑动窗口算法统计调用频率<br>5. 如调用次数未超限：<br>调用次数+1，更新 Redis 缓存<br>正常处理请求，返回推理结果<br>6. 如调用次数已超限：<br>拒绝请求<br>返回 HTTP 429 Too Many Requests<br>返回限流信息（重试时间、当前调用次数）<br>记录限流日志<br>如频繁触发限流，系统告警 |      |            |

|       |                                                                                                                                                                                                            |
|-------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 其他事件流 | <ol style="list-style-type: none"> <li>支持动态调整限流阈值（根据系统负载）</li> <li>支持白名单机制（重要应用不受限流）</li> <li>支持按时间段调整限流（高峰期降低阈值）</li> </ol>                                                                               |
| 异常处理  | <ol style="list-style-type: none"> <li>Redis 连接失败：降级为本地计数，警告日志</li> <li>限流策略加载失败：使用默认限流策略</li> <li>标识提取失败：使用默认限流策略</li> </ol>                                                                              |
| 业务规则  | <ol style="list-style-type: none"> <li>默认限流阈值：每分钟 100 次</li> <li>限流时间窗口：60 秒滑动窗口</li> <li>支持 3 种限流维度：用户、IP、API Key</li> <li>限流响应头：X-RateLimit-Limit 、 X-RateLimit-Remaining 、 X-RateLimit-Reset</li> </ol> |

表 15 差分隐私保护

|      |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |      |            |
|------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|------------|
| 用例编号 | OFFLINE_AI_MODEL_DifferentialPrivacy                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    | 用例名称 | 差分隐私保护     |
| 编写者  | 学生小组                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    | 时间   | 2026-03-23 |
| 触发事件 | 训练任务配置阶段启用差分隐私                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |      |            |
| 用例描述 | 在模型训练过程中，通过向梯度添加噪声来保护训练数据的隐私性，满足 $\epsilon$ -differential privacy 定义，防止反推个体数据                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           |      |            |
| 参与者  | AI 算法工程师、系统                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |      |            |
| 前提条件 | <ol style="list-style-type: none"> <li>训练任务已创建</li> <li>用户配置了差分隐私参数</li> </ol>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |      |            |
| 后续条件 | <ol style="list-style-type: none"> <li>训练过程中添加了噪声</li> <li>满足 <math>\epsilon</math>-differential privacy 定义</li> <li>隐私审计报告已生成</li> </ol>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               |      |            |
| 主事件流 | <ol style="list-style-type: none"> <li>用户在训练配置中启用差分隐私</li> <li>用户配置差分隐私参数 <ul style="list-style-type: none"> <li><math>\epsilon</math>（隐私预算）：推荐值 1.0-10.0</li> <li><math>\delta</math>（失败概率）：推荐值 1e-5</li> <li>噪声机制：Gaussian/Laplace</li> <li>梯度裁剪阈值：推荐值 1.0</li> </ul> </li> <li>系统验证参数合理性</li> <li>训练开始后，系统在每个训练 Step 执行差分隐私保护 <ul style="list-style-type: none"> <li>计算梯度</li> <li>梯度裁剪（限制梯度范数）</li> <li>添加高斯噪声（根据 <math>\epsilon</math> 和 <math>\delta</math> 计算噪声标准差）</li> <li>更新模型参数</li> </ul> </li> <li>系统实时消耗隐私预算 <math>\epsilon</math></li> <li>训练结束时，生成隐私审计报告 <ul style="list-style-type: none"> <li>累计消耗的隐私预算</li> <li>实际达到的 <math>\epsilon</math> 值</li> <li>隐私保证说明</li> <li>噪声统计信息</li> </ul> </li> </ol> |      |            |

|       |                                                                                                                                                                                                                             |
|-------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 其他事件流 | <ol style="list-style-type: none"> <li>1. 如隐私预算耗尽，训练自动停止</li> <li>2. 如需要提高模型精度，可动态调整 <math>\epsilon</math>（需记录）</li> <li>3. 如需要更强的隐私保护，可降低 <math>\epsilon</math></li> </ol>                                                 |
| 异常处理  | <ol style="list-style-type: none"> <li>1. 参数配置不合理：提示推荐值</li> <li>2. 噪声生成失败：使用默认噪声机制，记录警告</li> <li>3. 隐私预算耗尽：自动停止训练，通知用户</li> </ol>                                                                                          |
| 业务规则  | <ol style="list-style-type: none"> <li>1. <math>\epsilon</math> 越小，隐私保护越强，但模型精度可能下降</li> <li>2. 推荐 <math>\epsilon</math> 范围：1.0-10.0</li> <li>3. 推荐 <math>\delta</math> 范围：1e-5 到 1e-6</li> <li>4. 隐私预算不可超支，不可重置</li> </ol> |

表 16 联邦学习

|       |                                                                                                                                                                                                                                                                                                                                                                                                  |      |            |
|-------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|------------|
| 用例编号  | OFFLINE_AI_MODEL_FederatedLearning                                                                                                                                                                                                                                                                                                                                                               | 用例名称 | 联邦学习       |
| 编写者   | 学生小组                                                                                                                                                                                                                                                                                                                                                                                             | 时间   | 2026-03-23 |
| 触发事件  | 多个数据提供方协作训练模型                                                                                                                                                                                                                                                                                                                                                                                    |      |            |
| 用例描述  | 实现联邦学习框架，支持分布式多方协作训练，通过参数交换实现模型训练，保护数据隐私                                                                                                                                                                                                                                                                                                                                                         |      |            |
| 参与者   | 数据提供方、系统                                                                                                                                                                                                                                                                                                                                                                                         |      |            |
| 前提条件  | <ol style="list-style-type: none"> <li>1. 多个参与方已注册</li> <li>2. 参与方已部署本地训练环境</li> </ol>                                                                                                                                                                                                                                                                                                           |      |            |
| 后续条件  | <ol style="list-style-type: none"> <li>1. 全局模型已训练完成</li> <li>2. 各方数据未外泄</li> <li>3. 训练日志已记录</li> </ol>                                                                                                                                                                                                                                                                                           |      |            |
| 主事件流  | <ol style="list-style-type: none"> <li>1. 在内存中创建全局模型，耗时 5 至 15 秒</li> <li>2. 主进程向各模拟参与方分发模型参数，通过共享内存传递</li> <li>3. 各模拟参与方加载全局模型，将模型加载至 GPU 显存</li> <li>4. 各模拟参与方串行执行本地训练。依次使用 GPU 完成前向、反向传播及差分隐私处理</li> <li>5. 各模拟参与方提交模型更新，写入共享内存</li> <li>6. 主进程收集所有更新</li> <li>7. 主进程执行联邦聚合，加权平均生成新全局模型</li> <li>8. 主进程更新全局模型，写入共享内存</li> <li>9. 重复步骤 3-8，直到达到训练轮数或收敛条件</li> <li>10. 训练结束，保存最终全局模型</li> </ol> |      |            |
| 其他事件流 | <ol style="list-style-type: none"> <li>1. 如检测到恶意参与方（上传异常参数），降低其权重或移除</li> <li>2. 如需要动态增减参与方，支持参与方中途加入或退出</li> </ol>                                                                                                                                                                                                                                                                              |      |            |
| 异常处理  | <ol style="list-style-type: none"> <li>1. 参数聚合异常：跳过异常参与方</li> <li>2. 模型更新上传失败：自动重试 3 次，失败则跳过当前轮</li> </ol>                                                                                                                                                                                                                                                                                       |      |            |

|      |                                                                                      |
|------|--------------------------------------------------------------------------------------|
| 业务规则 | 1. 支持的联邦学习算法：FedAvg、FedProx、FedNova 等<br>2. 参与方数量：2-100 个<br>3. 训练轮数：可配置，推荐 10-100 轮 |
|------|--------------------------------------------------------------------------------------|

2.2.4 大模型应用模块

a) 大模型应用模块用例图：

下图为大模型应用模块的用例图，明确了模块的操作用户（软件开发工程师）、核心用例（文档自动生成）及用例的包含/扩展关系，定义了模块的功能范围与交互逻辑。




图 5 大模型应用模块用例图


b) 需求用例描述：

表 17 文档自动生成

|      |                                                                                              |      |            |
|------|----------------------------------------------------------------------------------------------|------|------------|
| 用例编号 | OFFLINE_AI_APP_DocGenerate                                                                   | 用例名称 | 文档自动生成     |
| 编写者  | 学生小组                                                                                         | 时间   | 2026-03-23 |
| 触发事件 | 软件开发工程师提交文档生成请求                                                                              |      |            |
| 用例描述 | 基于大语言模型，自动生成软件系统开发文档，包括需求分析、系统设计、接口文档、用户手册等类型                                                |      |            |
| 参与者  | 软件开发工程师、大模型、系统                                                                               |      |            |
| 前提条件 | 1. 用户已登录系统<br>2. 大模型服务已部署<br>3. 提供了需求描述或代码库                                                  |      |            |
| 后续条件 | 1. 文档已生成<br>2. 文档质量已检查<br>3. 文档已导出并可下载                                                       |      |            |
| 主事件流 | 1. 用户进入文档生成界面<br>2. 用户选择文档类型<br>3. 用户输入内容（2 种方式可选）<br>方式 1：自然语言描述<br>输入需求说明<br>描述系统功能、架构、接口等 |      |            |

|       |                                                                                                                                                                                                                                                                                                                                                                     |
|-------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|       | <p>方式 2：模板导入</p> <p>选择文档模板</p> <p>填写关键信息</p> <p>4. 用户点击“生成文档”</p> <p>5. 系统将用户输入转换为大模型 Prompt</p> <p>6. 大模型生成文档内容</p> <p>7. 系统进行内容质量检查</p> <p>结构完整性检查</p> <p>逻辑一致性检查</p> <p>专业术语准确性检查</p> <p>格式规范性检查</p> <p>8. 系统格式化文档内容（Markdown 格式）</p> <p>9. 用户在线预览文档</p> <p>10. 用户可进行编辑和优化</p> <p>11. 用户选择导出格式（Markdown/HTML/PDF/Word）</p> <p>12. 系统生成文档文件</p> <p>13. 用户下载文档</p> |
| 其他事件流 | <p>1. 如生成质量不佳，用户可选择重新生成</p> <p>2. 如需要补充内容，用户可继续输入信息，大模型追加生成</p> <p>3. 如需要特定格式，用户可上传参考文档，大模型学习风格</p>                                                                                                                                                                                                                                                                 |
| 异常处理  | <p>1. 大模型生成失败：返回错误信息，建议简化需求或分段生成</p> <p>2. 代码库分析失败：提示检查代码格式或压缩包完整性</p> <p>3. 质量检查不通过：高亮问题区域，提示用户修改</p>                                                                                                                                                                                                                                                              |
| 业务规则  | <p>1. 支持分段生成</p> <p>2. 生成内容保留 3 天，可重复导出</p>                                                                                                                                                                                                                                                                                                                         |

功能图



### 2.2.5 系统管理模块

#### a) 大模型应用模块用例图：

下图为系统管理模块的用例图，明确了模块的操作用户（系统管理员、项目管理者）、核心用例（日志管理、用户管理、角色权限管理、监控大屏展示）及用例的包含/扩展关系，定义了模块的功能范围与交互逻辑。




图 6 大模型应用模块用例图

b) 需求用例描述：

表 18 日志管理

|      |                                                                                    |      |            |
|------|------------------------------------------------------------------------------------|------|------------|
| 用例编号 | OFFLINE_AI_SYS_LogManage                                                           | 用例名称 | 日志管理       |
| 编写者  | 学生小组                                                                               | 时间   | 2026-03-23 |
| 触发事件 | 系统运行产生日志                                                                           |      |            |
| 用例描述 | 自动采集系统各模块的运行日志，存储到 Elasticsearch，支持全文检索、统计分析、日志导出和异常告警                             |      |            |
| 参与者  | 系统管理员、运维工程师、系统                                                                     |      |            |
| 前提条件 | 1. Elasticsearch 已部署<br>2. 日志采集 Agent 已部署                                          |      |            |
| 后续条件 | 1. 日志已存储<br>2. 支持查询和分析                                                             |      |            |
| 主事件流 | 1. 系统自动采集各模块日志（应用日志、系统日志、访问日志）<br>2. 日志采集 Agent 实时收集日志<br>3. 日志格式化为 JSON 格式<br>时间戳 |      |            |

|       |                                                                                                                                                                                                                                                                                                             |
|-------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|       | 日志级别（DEBUG/INFO/WARNING/ERROR/CRITICAL）<br>模块名称<br>消息内容<br>关联信息（用户 ID、任务 ID 等）<br>4. 日志写入 Elasticsearch<br>5. 用户查询日志<br>输入查询条件（关键词、时间范围、日志级别、模块）<br>系统执行全文检索<br>返回日志列表（支持分页）<br>6. 用户分析日志<br>统计日志级别分布<br>统计错误日志趋势<br>统计模块访问量<br>7. 用户导出日志（CSV 或 TXT 格式）<br>8. 系统自动检测异常日志（ERROR/CRITICAL）<br>9. 系统生成告警并通知管理员 |
| 其他事件流 | 1. 支持日志实时流（WebSocket 推送）<br>2. 支持日志高亮显示（关键词、错误信息）<br>3. 支持日志关联分析（根据任务 ID 追踪完整日志链）                                                                                                                                                                                                                           |
| 异常处理  | 1. 日志采集失败：自动重试，记录错误<br>2. Elasticsearch 写入失败：降级到本地文件，后台重试<br>3. 查询超时：提示缩小查询范围或分批查询                                                                                                                                                                                                                          |
| 业务规则  | 1. 日志保留策略：详细日志 90 天，压缩日志 1 年<br>2. 日志查询权限：按模块控制<br>3. 异常告警阈值：ERROR 日志>10/分钟触发告警                                                                                                                                                                                                                             |

表 19 用户管理

|      |                                                                                                                            |      |            |
|------|----------------------------------------------------------------------------------------------------------------------------|------|------------|
| 用例编号 | OFFLINE_AI_SYS_UserManage                                                                                                  | 用例名称 | 用户管理       |
| 编写者  | 学生小组                                                                                                                       | 时间   | 2026-03-23 |
| 触发事件 | 系统管理员管理用户或用户登录                                                                                                             |      |            |
| 用例描述 | 提供用户的全生命周期管理，包括创建、修改、删除用户，以及用户登录认证、权限管理                                                                                    |      |            |
| 参与者  | 系统管理员、用户、系统                                                                                                                |      |            |
| 前提条件 | 1. 系统已部署<br>2. 数据库已初始化                                                                                                     |      |            |
| 后续条件 | 1. 用户信息已更新<br>2. 用户状态已管理                                                                                                   |      |            |
| 主事件流 | 1. 创建用户： <ul style="list-style-type: none"> <li>1.1 管理员进入用户管理界面</li> <li>1.2 点击“创建用户”按钮</li> <li>1.3 填写用户信息</li> </ul> 用户名 |      |            |



|       |                                                                                                                                                                                                                                                                                                                                                                                      |
|-------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|       | 姓名<br>邮箱<br>手机号<br>密码<br>1.4 分配用户角色<br>1.5 设置用户状态（正常/锁定/禁用）<br>1.6 保存用户信息<br>2. 修改用户：<br>2.1 管理员选择要修改的用户<br>2.2 修改用户信息<br>2.3 调整用户角色<br>2.4 更新用户状态<br>2.5 保存修改<br>3. 删除用户：<br>3.1 管理员选择要删除的用户<br>3.2 系统提示确认（检查用户是否有关联数据）<br>3.3 管理员确认删除<br>3.4 系统删除用户数据（或标记为已删除）<br>4. 用户登录认证：<br>4.1 用户输入用户名和密码<br>4.2 系统验证用户名和密码<br>4.3 系统检查用户状态（是否禁用）<br>4.4 系统生成会话令牌<br>4.5 记录登录日志<br>4.6 返回登录成功 |
| 其他事件流 | 1. 用户可自行修改密码（需原密码）                                                                                                                                                                                                                                                                                                                                                                   |
| 异常处理  | 1. 用户名重复：提示更换用户名<br>2. 邮箱格式错误：提示正确格式<br>3. 密码强度不足：提示强度要求（至少 8 位，包含大小写字母、数字、特殊字符）<br>4. 用户删除失败：用户有关联数据（如训练任务），提示先处理关联数据                                                                                                                                                                                                                                                               |
| 业务规则  | 1. 用户名必须唯一<br>2. 密码至少 90 天更换一次<br>3. 连续登录失败 5 次锁定账户 30 分钟<br>4. 支持用户数量：至少 10000 个<br>5. 登录日志保留至少 90 天                                                                                                                                                                                                                                                                                |

表 20 角色权限管理

|      |                                       |      |            |
|------|---------------------------------------|------|------------|
| 用例编号 | OFFLINE_AI_SYS_RoleManage             | 用例名称 | 角色权限管理     |
| 编写者  | 学生小组                                  | 时间   | 2026-03-23 |
| 触发事件 | 系统管理员管理角色和权限                          |      |            |
| 用例描述 | 基于角色的访问控制（RBAC），支持创建角色、分配权限、用户分配角色，实现 |      |            |

|       |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   |
|-------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|       | 细粒度的权限管理                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |
| 参与者   | 系统管理员、用户、系统                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       |
| 前提条件  | 1. 系统已部署<br>2. 权限系统已初始化                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           |
| 后续条件  | 1. 角色已管理<br>2. 权限已分配<br>3. 用户权限已生效                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                |
| 主事件流  | <ol style="list-style-type: none"> <li>创建角色： <ol style="list-style-type: none"> <li>管理员进入角色管理界面</li> <li>点击“创建角色”按钮</li> <li>填写角色信息 <ul style="list-style-type: none"> <li>角色名称</li> <li>角色描述</li> <li>角色类型（管理员/普通用户）</li> </ul> </li> <li>分配权限给角色 <ul style="list-style-type: none"> <li>菜单权限（可访问的菜单）</li> <li>操作权限（增删改查）</li> <li>数据权限（可访问的数据范围）</li> </ul> </li> <li>保存角色</li> </ol> </li> <li>修改角色： <ol style="list-style-type: none"> <li>管理员选择要修改的角色</li> <li>修改角色信息</li> <li>调整角色权限</li> <li>保存修改</li> </ol> </li> <li>删除角色： <ol style="list-style-type: none"> <li>管理员选择要删除的角色</li> <li>系统检查角色是否被用户使用</li> <li>管理员确认删除</li> <li>删除角色和相关权限分配</li> </ol> </li> <li>用户分配角色： <ol style="list-style-type: none"> <li>管理员选择用户</li> <li>分配角色（支持多角色）</li> <li>用户权限为所有角色权限的并集</li> <li>保存分配</li> </ol> </li> </ol> |
| 其他事件流 | <ol style="list-style-type: none"> <li>支持权限模板（快速分配常用权限组合）</li> <li>支持角色继承（子角色继承父角色的权限）</li> <li>支持批量分配角色</li> </ol>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               |
| 异常处理  | <ol style="list-style-type: none"> <li>角色名称重复：提示更换角色名</li> <li>角色被用户使用：提示无法删除或提示先移除用户</li> <li>权限分配冲突：提示冲突的权限项</li> </ol>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |
| 业务规则  | <ol style="list-style-type: none"> <li>每个用户至少有一个角色</li> <li>用户可以有多个角色，权限为并集</li> <li>角色至少有一个权限</li> <li>支持至少 50 个角色</li> </ol>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    |

|  |                 |
|--|-----------------|
|  | 5. 权限验证在每次操作时执行 |
|--|-----------------|

表 21 监控大屏展示

|       |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    |      |            |
|-------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|------------|
| 用例编号  | OFFLINE_AI_SYS_MonitorDashboard                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    | 用例名称 | 监控大屏展示     |
| 编写者   | 学生小组                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               | 时间   | 2026-03-23 |
| 触发事件  | 用户打开监控大屏                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           |      |            |
| 用例描述  | 提供大屏可视化界面，实时展示系统运行状态、训练任务进度、资源使用率、告警信息等关键指标                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        |      |            |
| 参与者   | 项目管理者、运维工程师、系统                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     |      |            |
| 前提条件  | 1. 系统运行中<br>2. 监控数据已采集                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |      |            |
| 后续条件  | 1. 监控数据实时更新<br>2. 支持数据交互和钻取                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        |      |            |
| 主事件流  | 1. 用户打开监控大屏（全屏展示）<br>2. 系统实时推送监控数据（WebSocket）<br>3. 大屏展示多个模块 <ul style="list-style-type: none"> <li>3.1 系统状态概览               <ul style="list-style-type: none"> <li>在线任务数</li> <li>今日完成任务数</li> <li>告警数量</li> </ul> </li> <li>3.2 训练任务监控               <ul style="list-style-type: none"> <li>运行中的训练任务列表</li> <li>每个任务的进度（当前 Epoch/Step）</li> <li>损失曲线实时更新</li> <li>准确率变化趋势</li> </ul> </li> <li>3.3 资源使用监控               <ul style="list-style-type: none"> <li>GPU 利用率（柱状图）</li> <li>CPU 使用率（折线图）</li> <li>内存使用率（饼图）</li> <li>网络带宽使用（仪表盘）</li> </ul> </li> <li>3.4 告警信息展示               <ul style="list-style-type: none"> <li>实时告警列表</li> <li>告警级别（紧急/警告/通知）</li> <li>告警时间、内容</li> </ul> </li> </ul> 4. 用户可交互 <ul style="list-style-type: none"> <li>4.1 点击任务查看详情</li> <li>4.2 切换时间范围查看历史数据</li> <li>4.3 点击告警跳转到处理界面</li> </ul> |      |            |
| 其他事件流 | 1. 支持导出大屏截图或数据报告                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   |      |            |

|      |                                                                                       |
|------|---------------------------------------------------------------------------------------|
| 异常处理 | 1. WebSocket 连接断开：自动重连，显示连接状态<br>2. 数据更新延迟：提示网络问题，显示最后有效数据<br>3. 渲染失败：降级显示，记录错误日志     |
| 业务规则 | 1. 监控数据刷新频率：每 5 秒更新一次<br>2. 告警保留时间：24 小时<br>3. 历史数据保留：7 天<br>4. 大屏超时自动刷新：30 分钟无操作自动刷新 |

2.3 外部接口需求

本条可分为若干个小条来规定关于 CSCI 的外部接口的需求(若有)。本条可引用一个或多个接口需求规格说明(IRS)或包含这些需求的其他文档。

2.3.1 接口标识和接口图




图 7 软件外部接口示意图

接口标识说明

表 22 接口标识和接口图

| 标识符          | 接口名称        | 连接对象        | 协议/方式           | 数据流向 | 简要说明                               |
|--------------|-------------|-------------|-----------------|------|------------------------------------|
| EXT-LLMT-001 | Web 管理界面    | Web 浏览器（用户） | HTTP, WebSocket | 双向   | 提供 Web 管理后台，支持任务配置、数据上传、模型管理、监控查看等 |
| EXT-LLMT-002 | RESTful API | 第三方应用/脚本    | HTTP, REST      | 双向   | 提供标准编程接口，支持训练任务提交、模型推理、数据查询等       |

|              |         |                              |                      |    |                                 |
|--------------|---------|------------------------------|----------------------|----|---------------------------------|
| EXT-LLMT-003 | 模型推理接口  | 业务应用/下游系统                    | HTTP, gRPC           | 双向 | 提供在线推理服务，支持同步/异步调用              |
| EXT-LLMT-004 | 数据源接口   | 外部数据湖/数据仓库                   | PSYCOPG2, S3, Kafka  | 入向 | 导入训练数据集（批量/流式），支持多模态数据接入        |
| EXT-LLMT-005 | 模型仓库接口  | HuggingFace Hub, MLflow      | HTTP, S3             | 双向 | 导入/导出模型文件及元数据，实现模型版本共享与同步       |
| EXT-LLMT-006 | GPU 接口  | Kubernetes API, GPU Exporter | gRPC, NCCL           | 双向 | 获取 GPU 资源状态，提交训练任务，实现弹性资源调度     |
| EXT-LLMT-007 | 对象存储接口  | MinIO                        | S3/HTTP              | 双向 | 存储训练数据集、模型文件、Checkpoint 等非结构化数据 |
| EXT-LLMT-008 | 关系数据库接口 | PostgreSQL                   | PSYCOPG2             | 双向 | 存储用户信息、任务配置、模型元数据、系统参数等结构化数据    |
| EXT-LLMT-009 | 时序数据库接口 | InfluxDB                     | HTTP                 | 出向 | 写入训练过程指标（损失、准确率）、资源使用率等时序数据     |
| EXT-LLMT-010 | 日志存储接口  | Elasticsearch                | HTTP                 | 出向 | 输出应用日志、系统日志、访问日志，供检索与分析         |
| EXT-LLMT-011 | 监控指标接口  | Prometheus, Grafana          | HTTP (Prometheus 格式) | 出向 | 暴露系统性能指标（训练进度、资源使用、告警等）供外部采集    |

### 2.3.2 外部接口标识

本系统共定义 11 个外部接口，标识符为 EXT-LLMT-001 至 EXT-LLMT-011。

软件外部接口标识见下表。最终的接口关系及接口元素以后续签署的接口协议为准。

表 23 软件外部接口标识

| 序号 | 接口标识         | 接口名称        | 信源          | 信宿 | 协议类型              | 接口功能说明                                  |
|----|--------------|-------------|-------------|----|-------------------|-----------------------------------------|
| 1  | EXT-LLMT-001 | Web 管理界面    | Web 浏览器     | 系统 | HTTP/WebSocket    | 提供 Web 管理后台，支持用户登录、任务配置、数据上传、模型管理、监控查看等 |
| 2  | EXT-LLMT-002 | RESTful API | 第三方应用/脚本    | 系统 | HTTP/REST         | 提供标准编程接口，支持训练任务提交、模型推理、数据查询等            |
| 3  | EXT-LLMT-003 | 模型推理接口      | 业务应用/下游系统   | 系统 | HTTP/gRPC         | 提供在线推理服务，支持同步/异步调用                      |
| 4  | EXT-LLMT-004 | 数据源接口       | 外部数据湖/数据仓库  | 系统 | PSYCOPG2/S3/Kafka | 导入训练数据集（批量/流式），支持多模态数据接入                |
| 5  | EXT-LLMT-005 | 模型仓         | HuggingFace | 系  | HTTP/S3           | 导入/导出模型文                                |

| 序号 | 接口标识         | 接口名称    | 信源                          | 信宿 | 协议类型                 | 接口功能说明                          |
|----|--------------|---------|-----------------------------|----|----------------------|---------------------------------|
|    |              | 库接口     | Hub/MLflow                  | 统  |                      | 件及元数据,实现模型版本共享与同步               |
| 6  | EXT-LLMT-006 | GPU 接口  | Kubernetes API/GPU Exporter | 系统 | gRPC/NCCL            | 获取 GPU 资源状态,提交训练任务,实现弹性资源调度     |
| 7  | EXT-LLMT-007 | 对象存储接口  | MinIO                       | 系统 | S3/HTTP              | 存储训练数据集、模型文件、Checkpoint 等非结构化数据 |
| 8  | EXT-LLMT-008 | 关系数据库接口 | PostgreSQL                  | 系统 | PSYCOPG2             | 存储用户信息、任务配置、模型元数据、系统参数等结构化数据    |
| 9  | EXT-LLMT-009 | 时序数据库接口 | InfluxDB                    | 系统 | HTTP                 | 写入训练过程指标(损失、准确率)、资源使用率等时序数据     |
| 10 | EXT-LLMT-010 | 日志存储接口  | Elasticsearch               | 系统 | HTTP                 | 输出应用日志、系统日志、访问日志,供检索与分析         |
| 11 | EXT-LLMT-011 | 监控指标接口  | Prometheus/Grafana          | 系统 | HTTP (Prometheus 格式) | 暴露系统性能指标(训练进度、资源使用、告警等)供外部采集    |

1. EXT-LLMT-001 Web 管理界面
  - a) 接口标识: EXT-LLMT-001
  - b) 接口名称: Web 管理界面
  - c) 信源/信宿: 信源: Web 浏览器(用户端); 信宿: 系统应用层
  - d) 协议类型: HTTP (TLS 1.2+)、WebSocket
  - e) 数据元素: 页面资源(HTML/CSS/JS)、API 调用请求/响应(JSON)、实时推送消息(JSON)
  - f) 通信方式: 同步请求/响应(HTTP)、全双工实时推送(WebSocket)
  - g) 安全要求: 基于 JWT 的 Token 认证,支持 OAuth2.0 单点登录(可选),会话超时 30 分钟
2. EXT-LLMT-002 RESTful API
  - a) 接口标识: EXT-LLMT-002
  - b) 接口名称: RESTful API
  - c) 信源/信宿: 信源: 第三方应用、自动化脚本; 信宿: 系统应用层
  - d) 协议类型: HTTP (TLS 1.2+), REST
  - e) 数据元素: 请求/响应均为 JSON 格式,遵循 OpenAPI 3.0 规范
  - f) 通信方式: 同步请求/响应
  - g) 安全要求: API Key + Secret 签名,支持 OAuth2.0 Client Credentials,IP 白名单可选
3. EXT-LLMT-003 模型推理接口
  - a) 接口标识: EXT-LLMT-003

- b) 接口名称: 模型推理接口
  - c) 信源/信宿: 信源: 业务应用、下游系统; 信宿: 系统服务层
  - d) 协议类型: HTTP (REST)、gRPC
  - e) 数据元素: REST: JSON; gRPC: Protobuf (定义见.proto 文件)
  - f) 通信方式: 同步请求/响应, 支持批量推理
  - g) 安全要求: API Key 或 JWT 认证, gRPC 支持 mTLS
4. EXT-LLMT-004 数据源接口
- a) 接口标识: EXT-LLMT-004
  - b) 接口名称: 数据源接口
  - c) 信源/信宿: 信源: 外部数据湖、数据仓库、消息队列; 信宿: 系统数据层
  - d) 协议类型: PSYCO PG2、S3、Kafka
  - e) 数据元素: 结构化 (CSV、Parquet)、半结构化 (JSON)、非结构化 (文本、图像、音频)
  - f) 通信方式: 批量拉取 (PSYCO PG2/S3)、流式消费 (Kafka)
  - g) 安全要求: 数据库用户名/密码 (PSYCO PG2)、AWS Access Key (S3)、SASL/SSL (Kafka)
  - h) 其他: 支持断点续传、数据校验重试, 失败记录日志并告警
5. EXT-LLMT-005 模型仓库接口
- a) 接口标识: EXT-LLMT-005
  - b) 接口名称: 模型仓库接口
  - c) 信源/信宿: 信源: HuggingFace Hub、MLflow、内部模型仓库; 信宿: 系统业务层
  - d) 协议类型: HTTP、S3
  - e) 数据元素: 模型文件 (.bin、.pth、.safetensors)、元数据 (JSON、YAML)
  - f) 通信方式: 同步请求/响应 (上传/下载)
  - g) 安全要求: HuggingFace Token、MLflow 认证 (用户名/密码或 API Key)
  - h) 其他: 网络中断自动重试, 文件完整性校验, 版本冲突提示确认
6. EXT-LLMT-006 GPU 接口
- a) 接口标识: EXT-LLMT-006
  - b) 接口名称: GPU 接口
  - c) 信源/信宿: 信源: Kubernetes API、GPU Exporter、NCCL; 信宿: 系统基础设施层
  - d) 协议类型: HTTP (K8s API)、gRPC (自定义)、NCCL (GPU 间通信)
  - e) 数据元素: JSON、YAML (K8s 资源描述)、Protobuf
  - f) 通信方式: 同步请求/响应 (资源申请/释放)、异步事件 (Pod 状态变更)
  - g) 安全要求: Kubernetes RBAC + ServiceAccount Token, gRPC mTLS
  - h) 其他: 资源不足时排队等待, 节点故障自动迁移任务, 超时自动重试
7. EXT-LLMT-007 对象存储接口
- a) 接口标识: EXT-LLMT-007
  - b) 接口名称: 对象存储接口
  - c) 信源/信宿: 信源/信宿: MinIO (S3 兼容存储)
  - d) 协议类型: S3
  - e) 数据元素: 二进制文件 (数据集、模型、Checkpoint)
  - f) 通信方式: 同步请求/响应 (PUT/GET/DELETE)
  - g) 安全要求: Access Key + Secret Key, 支持 IAM 策略
  - h) 其他: 自动重试, 数据完整性校验, 超时阈值可配置
8. EXT-LLMT-008 关系数据库接口

- a) 接口标识: EXT-LLMT-008
  - b) 接口名称: 关系数据库接口
  - c) 信源/信宿: 信源/信宿: PostgreSQL
  - d) 协议类型: PSYCOPG2 (TCP)
  - e) 数据元素: SQL 语句、结果集
  - f) 通信方式: 同步请求/响应 (连接池)
  - g) 安全要求: 用户名/密码, SSL 加密连接
  - h) 其他: 事务回滚, 死锁自动重试, 慢查询日志记录
9. EXT-LLMT-009 时序数据库接口
- a) 接口标识: EXT-LLMT-009
  - b) 接口名称: 时序数据库接口
  - c) 信源/信宿: 信源/信宿: InfluxDB
  - d) 协议类型: HTTP
  - e) 数据元素: Line Protocol、JSON
  - f) 通信方式: 异步写入、同步查询
  - g) 安全要求: 用户名/密码, Token 认证
  - h) 其他: 写入失败本地缓存重试, 数据过期自动删除策略
10. EXT-LLMT-010 日志存储接口
- a) 接口标识: EXT-LLMT-010
  - b) 接口名称: 日志存储接口
  - c) 信源/信宿: 信源/信宿: Elasticsearch
  - d) 协议类型: HTTP (HTTP)
  - e) 数据元素: JSON (结构化日志)
  - f) 通信方式: 异步批量写入
  - g) 安全要求: 用户名/密码, API Key
  - h) 其他: 写入失败本地缓冲, 索引滚动自动管理
11. EXT-LLMT-011 监控指标接口
- a) 接口标识: EXT-LLMT-011
  - b) 接口名称: 监控指标接口
  - c) 信源/信宿: 信源/信宿: Prometheus、Grafana
  - d) 协议类型: HTTP (HTTP)
  - e) 数据元素: Prometheus Exposition Format (文本/Protobuf)
  - f) 通信方式: 拉取模式 (Prometheus 主动抓取)
  - g) 安全要求: Basic Auth、Bearer Token
  - h) 其他: 指标采集失败记录内部错误日志, 不影响主业务流程

## 2.4 内部接口需求

### 2.4.1 接口标识和接口图






图 8 软件内部接口示意图

表 24 接口标识说明

| 标识符          | 接口名称        | 连接对象             | 协议/方式                 | 数据流向 | 简要说明                 |
|--------------|-------------|------------------|-----------------------|------|----------------------|
| INT-LLMT-001 | 应用层 - 业务层接口 | 应用层与业务层          | HTTP, WebSocket, REST | 双向   | 用户交互、API 调用、监控数据推送   |
| INT-LLMT-002 | 业务层 - 服务层接口 | 业务层与服务层          | gRPC                  | 双向   | 训练任务提交、模型推理调用、资源调度请求 |
| INT-LLMT-003 | 服务层 - 数据层接口 | 服务层与数据层          | PSYCOGP2, S3, HTTP    | 双向   | 数据读写、指标存储、日志查询、文件存取  |
| INT-LLMT-004 | 数据处理与训练协同接口 | 数据处理模块与模型训练模块    | 共享存储 / API            | 双向   | 数据集版本传递、数据血缘同步       |
| INT-LLMT-005 | 训练与模型管理接口   | 模型训练模块 -> 模型管理模块 | gRPC                  | 单向   | 训练完成的模型注册、版本更新       |
| INT-LLMT-    | 模型管理        | 模型管理模            | gRPC                  | 双向   | 模型加载、推理服务调用          |

|              |             |            |                                      |    |                                |
|--------------|-------------|------------|--------------------------------------|----|--------------------------------|
| 006          | 与应用接口       | 块与大模型应用模块  |                                      |    |                                |
| INT-LLMT-007 | 训练服务与调度服务接口 | 训练服务与调度服务  | gRPC                                 | 双向 | 资源状态同步、任务调度协调                  |
| INT-LLMT-008 | 服务层-基础设施层接口 | 调度服务与基础设施层 | HTTP (K8sAPI), Docker API, gRPC/NCCL | 双向 | Pod 创建/销毁、容器管理、GPU 资源状态获取、任务提交 |

#### 2.4.2 内部接口标识

本系统共定义 8 个内部接口，标识符为 INT-LLMT-001 至 INT-LLMT-008，其基本对应关系如下表所示。

表 25 软件内部接口标识

| 序号 | 接口标识         | 接口名称        | 信源               | 信宿                                            | 协议类型                  | 接口功能说明                         |
|----|--------------|-------------|------------------|-----------------------------------------------|-----------------------|--------------------------------|
| 1  | INT-LLMT-001 | 应用层-业务层接口   | 应用层 (Web/API/监控) | 业务层各模块                                        | HTTP, WebSocket, REST | 用户交互、API 调用、监控数据推送             |
| 2  | INT-LLMT-002 | 业务层-服务层接口   | 业务层各模块           | 服务层 (训练/推理/调度)                                | gRPC                  | 训练任务提交、模型推理调用、资源调度请求           |
| 3  | INT-LLMT-003 | 服务层-数据层接口   | 服务层 (训练/推理/调度)   | 数据层 (PostgreSQL/InfluxDB/MinIO/Elasticsearch) | PSYCO2, S3, HTTP      | 数据读写、指标存储、日志查询、文件存取            |
| 4  | INT-LLMT-004 | 数据处理与训练协同接口 | 数据处理模块与模型训练模块    | 共享存储 / API / 消息队列                             | 双向                    | 数据集版本传递、训练状态反馈、数据血缘同步          |
| 5  | INT-LLMT-005 | 训练与模型管理接口   | 模型训练模块           | 模型管理模块                                        | gRPC                  | 训练完成的模型注册、版本更新                 |
| 6  | INT-LLMT-006 | 模型管理与应用接口   | 模型管理模块与大模型应用模块   | gRPC                                          | 双向                    | 模型加载、推理服务调用                    |
| 7  | INT-LLMT-007 | 训练服务与调度服务接口 | 训练服务与调度服务        | gRPC                                          | 双向                    | 资源状态同步、任务调度协调                  |
| 8  | INT-LLMT-008 | 服务层-基础设施层接口 | 调度服务与基础设施层       | HTTP (K8sAPI), Docker API, gRPC/NCCL          | 双向                    | Pod 创建/销毁、容器管理、GPU 资源状态获取、任务提交 |

##### 1. INT-LLMT-001 应用层-业务层接口

- 接口标识：INT-LLMT-001
- 接口名称：应用层-业务层接口
- 信源/信宿：信源：应用层；信宿：业务层
- 协议类型：HTTP、WebSocket、REST
- 数据元素：JSON 格式的 API 请求/响应、WebSocket 实时推送消息、页面静态资源
- 通信方式：同步请求/响应 (HTTP/REST)、全双工实时推送 (WebSocket)
- 安全要求：基于 JWT 的 Token 认证，支持 OAuth2.0 单点登录 (可选)，会话超时 30 分钟，内部接口支持 mTLS

- h) 其他：监控大屏数据实时刷新
- 2. INT-LLMT-002 业务层-服务层接口
  - a) 接口标识：INT-LLMT-002
  - b) 接口名称：业务层-服务层接口
  - c) 信源/信宿：信源：业务层；信宿：服务层
  - d) 协议类型：gRPC (HTTP/2)
  - e) 数据元素：Protobuf 格式的消息
  - f) 通信方式：同步请求/响应，支持双向流（状态同步）
  - g) 安全要求：mTLS 认证，服务间通信加密
  - h) 其他：训练任务提交、模型推理调用、资源调度请求均通过此接口实现
- 3. INT-LLMT-003 服务层-数据层接口
  - a) 接口标识：INT-LLMT-003
  - b) 接口名称：服务层-数据层接口
  - c) 信源/信宿：信源：服务层；信宿：数据层
  - d) 协议类型：PSYCO2PG2、S3、HTTP
  - e) 数据元素：SQL 语句及结果集、文件二进制内容及元数据、时序数据、日志数据（JSON）
  - f) 通信方式：同步请求/响应，支持批量写入
  - g) 安全要求：数据库用户名/密码；S3 使用 Access Key/Secret Key；
- 4. INT-LLMT-004 数据处理与训练协同接口
  - a) 接口标识：INT-LLMT-004
  - b) 接口名称：数据处理与训练协同接口
  - c) 信源/信宿：信源：数据处理模块；信宿：模型训练模块；反向：模型训练模块 → 数据处理模块
  - d) 协议类型：共享存储、gRPC/REST API、Kafka 消息队列
  - e) 数据元素：JSON 格式的消息
  - f) 通信方式：共享存储（文件传递）、同步 API 调用、异步消息推送
  - g) 安全要求：内部服务认证，消息队列支持 SASL/SSL
- 5. INT-LLMT-005 训练与模型管理接口
  - a) 接口标识：INT-LLMT-005
  - b) 接口名称：训练与模型管理接口
  - c) 信源/信宿：信源：模型训练模块；信宿：模型管理模块
  - d) 协议类型：gRPC
  - e) 数据元素：Protobuf 格式的消息
  - f) 通信方式：同步请求/响应
  - g) 安全要求：mTLS 认证
  - h) 其他：训练完成后自动注册模型，记录训练超参数和性能指标
- 6. INT-LLMT-006 模型管理与应用接口
  - a) 接口标识：INT-LLMT-006
  - b) 接口名称：模型管理与应用接口
  - c) 信源/信宿：信源：模型管理模块；信宿：大模型应用模块；反向：大模型应用模块 → 模型管理模块
  - d) 协议类型：gRPC，支持流式传输
  - e) 数据元素：Protobuf 格式的消息
  - f) 通信方式：同步请求/响应，流式返回（生成长文档）

- g) 安全要求: mTLS 认证
- h) 其他: 支持模型热加载和版本切换, 应用模块通过此接口调用模型生成文档
7. INT-LLMT-007 训练服务与调度服务接口
- a) 接口标识: INT-LLMT-007
- b) 接口名称: 训练服务与调度服务接口
- c) 信源/信宿: 信源: 训练服务; 信宿: 调度服务; 反向: 调度服务 → 训练服务
- d) 协议类型: gRPC, 支持双向流
- e) 数据元素: Protobuf 格式的消息
- f) 通信方式: 同步请求/响应、双向流
- g) 安全要求: mTLS 认证, 服务发现使用 Kubernetes
- h) 其他: 调度服务负责 GPU 资源分配和任务生命周期管理
8. INT-LLMT-008 服务层-基础设施层接口
- a) 接口标识: INT-LLMT-008
- b) 接口名称: 服务层-基础设施层接口
- c) 信源/信宿: 信源: 调度服务; 信宿: Kubernetes、Docker、GPU
- d) 协议类型: HTTP (Kubernetes API)、Docker API、gRPC/NCCL (GPU 通信)
- e) 数据元素: Pod 定义 (YAML/JSON)、容器创建参数、GPUStatus、ComputeTask
- f) 通信方式: 同步请求/响应 (Pod 创建/销毁、容器管理)、异步状态查询 (GPU 状态)
- g) 安全要求: Kubernetes RBAC + ServiceAccount Token; Docker API 使用 TLS 客户端证书; gRPC 使用 mTLS
- h) 其他: 容器镜像使用私有仓库

## 2.5 CSCI 内部数据需求

本系统内部数据主要包括以下核心实体, 具体数据模型和表结构设计留待概要设计阶段完成。

表 26 核心数据实体说明


| 数据实体   | 存储介质       | 数据量级预估      | 关键约束                   | 说明                  |
|--------|------------|-------------|------------------------|---------------------|
| 用户信息   | PostgreSQL | ≤ 100 条     | 唯一性 (用户名)、加密存储 (密码)    | 系统用户账户、角色、权限信息      |
| 任务信息   | PostgreSQL | ≤ 500 条     | 任务 ID 唯一, 状态流转可追溯      | 训练任务、推理任务的配置和执行记录   |
| 模型元数据  | PostgreSQL | ≤ 100 条     | 模型 ID+版本唯一, 与任务 ID 关联  | 模型版本、超参数、性能指标、存储路径  |
| 数据集元数据 | PostgreSQL | ≤ 100 条     | 数据集 ID 唯一, 血缘关系可追溯     | 数据集版本、来源、格式、大小、校验信息 |
| 训练指标   | InfluxDB   | 每天 ≤ 1 万点   | 时序数据, 自动过期策略 (保留 30 天) | 损失曲线、GPU 利用率、吞吐量等   |
| 模型文件   | MinIO      | 单个 ≤ 500MB, | 文件完整性校验                | 训练产出的模型权重           |

| 数据实体  | 存储介质          | 数据量级预估             | 关键约束             | 说明             |
|-------|---------------|--------------------|------------------|----------------|
|       |               | 总量≤10GB            | (ETag)，版本不可变     | 文件、Checkpoint  |
| 数据集文件 | MinIO         | 单个≤5GB，<br>总量≤50GB | 文件完整性校验，支持分片上传   | 训练使用的多模态数据文件   |
| 系统日志  | Elasticsearch | 每天 ≤ 50MB          | 日志保留 30 天，支持全文检索 | 应用日志、访问日志、系统日志 |


2.6 界面要求

本项所列均为示例，一切以实现为准。


仪表盘界面：




数据处理界面：




模型训练界面：




模型管理界面：



模型生成界面：



系统管理界面：



2.7 适应性需求

本系统应具备基本的适应性，能够在不同硬件环境和运行条件下灵活配置。

a) 硬件环境适应性

系统应支持 NVIDIA GPU（如 RTX 3090、V100、A100 等），通过配置文件或 Web 管理界面设置 GPU 型号和数量，无需修改代码。

系统应支持单机单卡部署模式，通过配置文件或 Web 管理界面指定使用的 GPU 数量并自动调正数据并行策略。

系统应支持通过配置文件指定数据集、模型文件、日志文件的存储路径，支持本地磁盘和网络存储。

b) 数据源适应性

系统支持从本地文件系统读取数据集，数据集路径通过 Web 管理界面指定上传。

系统支持文本（TXT、JSON、CSV）等常见格式，可扩展新格式。

c) 部署适应性



系统各模块可独立启停，根据实际需求选择性部署部分功能。

系统启动时读取后端配置文件（如数据库连接、存储路径等），这些属于部署级配置，由运维人员设置，与用户运行参数分开。

## 2.8 安全性需求

本系统为保障软件安全可靠运行，在数据安全、访问控制、模型安全和系统容错等方面进行基本的安全性设计。

### a) 数据安全

数据传输加密：对外接口采用 HTTP 协议传输。

敏感数据存储：用户密码采用 bcrypt 加密存储。

数据访问控制：通过角色权限控制用户对资源的访问。

### b) 访问控制

用户认证：采用 JWT 进行身份认证。

权限管理：支持管理员、普通用户等基本角色。

会话管理：会话超时后自动登出。

### c) 模型安全

模型版本控制：支持 Git-like 模型版本管理，可回滚至历史版本。

API 调用限流：模型服务 API 限制调用频率，防止滥用。

### d) 运行安全

操作确认：关键操作（删除模型、终止任务）进行二次确认。

异常恢复：训练异常时保存 Checkpoint，支持恢复训练。

### e) 安全审计

操作日志：记录关键操作日志，包括操作人、操作时间、操作内容

## 2.9 CSCI 环境需求

本条环境需求见后续开发手册

## 2.10 软件质量因素

本系统在设计上应注重可维护性、可扩展性、可靠性、易用性等软件质量属性，保障系统长期稳定运行和持续演进。

### a) 可维护性

采用分层解耦架构（应用层、业务层、服务层、数据层、基础设施层），各层职责清晰，降低模块间耦合度。

遵循代码规范，关键业务逻辑添加注释，便于后续维护和交接。

提供统一的日志输出格式和级别，便于问题定位和排查。

### b) 可扩展性

数据处理模块支持自定义 Dataset 类，便于扩展新的数据格式和预处理逻辑。

模型训练模块通过配置文件定义训练参数，新增模型类型无需修改代码。

数据与视图分离，前端界面与后端逻辑解耦，便于独立修改和升级。

### c) 可靠性

训练任务支持 Checkpoint 自动保存和恢复，异常中断后可继续训练。

### d) 易用性

提供 Web 管理界面，支持可视化操作，降低使用门槛。

训练任务配置提供默认参数和提示信息，用户可根据需求修改。

系统提供操作引导和帮助文档，便于用户快速上手。

### e) 效率

数据集采用分批加载和缓存机制，减少 I/O 等待时间。



## f) 可移植性

系统支持容器化部署，提供 Docker 镜像，可在不同环境下快速部署。

关键配置（数据库连接、存储路径等）通过环境变量或配置文件管理，便于迁移。

依赖库通过 requirements.txt 管理，支持在虚拟环境中快速重建运行环境。

## 2.11 设计和实现约束

本条本系统的设计和实现应遵循以下约束条件：

## a) 编程语言与开发框架

后端开发语言：采用 Python 3.8 及以上版本。

Web 框架：采用 FastAPI 构建 RESTful API 接口。

前端框架：采用 Vue.js 3.0 + Element Plus 构建 Web 管理界面。

训练框架：集成 PyTorch、DeepSpeed、Megatron-LM 等主流训练框架。

## b) 体系结构约束

系统采用五层分层解耦架构（应用层、业务层、服务层、数据层、基础设施层）。

业务层与服务层之间通过 gRPC 进行通信，服务层与数据层之间采用 PSYCOPG2、S3、HTTP 等标准协议。

数据与视图分离，前后端通过 RESTful API 交互。

## c) 数据库与存储

关系型数据库：采用 PostgreSQL 存储用户信息、任务配置、模型元数据等结构化数据。

时序数据库：采用 InfluxDB 存储训练指标等时序数据。

对象存储：采用 MinIO（S3 兼容）存储数据集、模型文件等非结构化数据。

日志存储：采用 Elasticsearch 存储系统日志，支持全文检索。

## d) 设计标准

API 设计遵循 RESTful 规范，自动生成 OpenAPI 文档。

代码遵循 PEP 8 编码规范，关键逻辑添加注释。

数据库设计遵循第三范式，关键表建立索引。

## e) 部署约束

支持 Docker 容器化部署，提供 Dockerfile 和 docker-compose.yml。

## 3 需求可追踪性

表 27 需求可追踪性表

| 需求名称    | 标识                                 | 章条号   | 技术要求名称 |
|---------|------------------------------------|-------|--------|
| 多模态数据加载 | OFFLINE_AI_DATA_LoadData           | 3.2.1 | 数据管理   |
| 数据质量校验  | OFFLINE_AI_DATA_ValidateData       |       |        |
| 数据血缘追踪  | OFFLINE_AI_DATA_LineageTrack       |       | 数据治理   |
| 分布式训练启动 | OFFLINE_AI_TRAIN_StartTrainin<br>g | 3.2.2 | 模型训练   |
| 混合并行配置  | OFFLINE_AI_TRAIN_ConfigurePar      |       |        |

|            |                                      |       |      |
|------------|--------------------------------------|-------|------|
|            | allel                                |       |      |
| 训练任务监控     | OFFLINE_AI_TRAIN_MonitorTraining     |       |      |
| 训练任务动态扩容   | OFFLINE_AI_TRAIN_ScaleTraining       |       | 资源调度 |
| 模型版本管理     | OFFLINE_AI_MODEL_VersionControl      |       | 模型管理 |
| 模型版本回滚     | OFFLINE_AI_MODEL_Rollback            |       |      |
| 容器镜像漏洞扫描   | OFFLINE_AI_MODEL_ClaireScan          | 3.2.3 | 模型安全 |
| API 调用频率限制 | OFFLINE_AI_MODEL_RateLimit           |       |      |
| 差分隐私保护     | OFFLINE_AI_MODEL_DifferentialPrivacy |       | 数据隐私 |
| 文档自动生成     | OFFLINE_AI_APP_DocGenerate           | 3.2.4 | 应用服务 |
| 用户管理       | OFFLINE_AI_SYS_UserManage            |       |      |
| 角色权限管理     | OFFLINE_AI_SYS_RoleManage            | 3.2.5 | 系统管理 |
| 日志管理       | OFFLINE_AI_SYS_LogManage             |       |      |

#### 4 注释

本章提供有助于理解本规格说明书的背景信息、术语定义、缩略语说明及相关参考资料。

##### 术语定义

多模态数据：包含文本、图像、音频等多种形式的结构化或非结构化数据。

数据血缘：记录数据从来源、转换到最终使用的完整溯源信息。

混合并行：同时使用数据并行、模型并行、流水线并行等多种并行策略的分布式训练方式。

Checkpoint：训练过程中保存的模型状态快照，用于故障恢复或断点续训。

差分隐私：通过在训练过程中添加噪声，防止从模型输出反推个体数据的技术。

联邦学习：多参与方在本地训练模型，仅上传模型更新参数而不共享原始数据的分布式学习方式。

##### 缩略语

CSCI：Computer Software Configuration Item，计算机软件配置项。

API：Application Programming Interface，应用程序编程接口。

JWT：JSON Web Token，JSON 网络令牌。

RBAC：Role-Based Access Control，基于角色的访问控制。

gRPC: gRPC Remote Procedure Call, gRPC 远程过程调用。

REST: Representational State Transfer, 表述性状态转移。

S3: Simple Storage Service, 简单存储服务。

PSYCOPG2: PostgreSQL 数据库适配器, Python 连接 PostgreSQL 的常用驱动。

NCCL: NVIDIA Collective Communications Library, NVIDIA 集合通信库。

K8s: Kubernetes, 容器编排平台。

IRS: Interface Requirements Specification, 接口需求规格说明。